Частотно-ориентированная обработка для субъект-инвариантного распознавания жестов по сигналам пЭМГ: от декомпозиции сигнала к побандовому смешиванию стилей

К. С. Голован, И. А. Зверева
Департамент информационных технологий
Национальный исследовательский университет «Высшая школа экономики»
Москва, Россия
kgolovan@edu.hse.ru

Аннотация—Межсубъектная генерализация остаётся ключевой проблемой в распознавании жестов по поверхностной электромиографии (пЭМГ). Мы показываем, что субъект-инвариантность в пЭМГ лучше достигается не через глобальную нормализацию, а через частотно-селективную обработку: межсубъектная вариабельность неравномерна по спектру (десятикратный градиент нормированного CV), поэтому низкочастотные полосы, несущие информацию о жесте, следует сохранять, а высокочастотные — нормализовать.

Предлагаемый конвейер декомпозирует сигнал на четыре поддиапазона (фиксированный Sinc или обучаемый UVMD) и применяет побандовый MixStyle. Декомпозиция — основной вклад (+3,7 п. п. macro-F1, $d = 1{,}25$); побандовая аугментация стилей добавляет +1,1–1,8 п. п.. Глобальные альтернативы — равномерная Instance Normalization и состязательное разделение контента и стиля — ухудшают качество на −2,6 – −8,5 п. п.. Предложенный SCG-Net обучает почти бинарный побандовый гейт, удаляющий стиль только из высокочастотной полосы, что количественно подтверждает частотную структуру вариабельности.

Итоговый конвейер достигает 37,7% macro-F1 на NinaPro DB2 (20 субъектов, 10 жестов, LOSO) по сравнению с бейзлайном 33,5%.

Index Terms—пЭМГ, распознавание жестов, межсубъектная генерализация, частотная декомпозиция, аугментация стилей, доменная генерализация

I. Введение

Поверхностная электромиография (пЭМГ) позволяет неинвазивно регистрировать произвольную мышечную активацию и является ключевой модальностью для управления протезами кисти [1], реабилитации [3] и взаимодействия человека с компьютером [4]. Критическим препятствием для практического применения является межсубъектная вариабельность: модели, обученные на группе субъектов, резко деградируют при применении к новому, невиденному пользователю из-за различий в расположении электродов, импедансе кожи, толщине подкожной клетчатки и индивидуальных паттернов рекрутирования моторных единиц [5].

Классические подходы к этой проблеме включают перенос обучения [6], доменную адаптацию [7] и ручное конструирование признаков с временными дескрипторами (TD), подаваемыми в машины опорных векторов (SVM) [8]. В последнее время архитектуры глубокого обучения — свёрточные нейронные сети (CNN), вентильные рекуррентные блоки (GRU), временные свёрточные сети (TCN) — применяются непосредственно к окнам необработанного пЭМГ [1], [6], однако межсубъектный разрыв сохраняется.

Центральный тезис данной работы состоит в том, что субъект-инвариантность в пЭМГ лучше достигается не через глобальную инвариантность (равномерную нормализацию, состязательное разделение), а через частотно-селективную обработку: низкочастотные полосы, несущие информацию о жесте, необходимо сохранять, тогда как высокочастотные, доминированные субъектным шумом, следует нормализовать или рандомизировать.

Это утверждение опирается на эмпирическое наблюдение: межсубъектная спектральная вариабельность неравномерна — нормированный коэффициент вариации растёт в десять раз от полосы моторных единиц к высокочастотному хвосту. Мы показываем, что конвейер, декомпозирующий сигнал на поддиапазоны и применяющий побандовую аугментацию стилей, устойчиво превосходит как монолитные модели, так и подходы с глобальной инвариантностью.

Работа выполнена на датасете NinaPro DB2 [2] при строгом LOSO с участием 20 субъектов и 10 жестов (Exercise E1).

a) Вклад работы.:

1) Количественное обоснование частотно-селективной обработки: межсубъектная вариабельность зависит от частоты (CV 10:1), а глобальные подходы к инвариантности (IN, состязательное разделение) разрушают информацию о жестах.

2) Конвейер частотно-ориентированной обработки: декомпозиция на $K = 4$ полосы + побандовый MixStyle, дающий суммарно +4,8–5,2 п. п. F1 над монолитным бейзлайном.
3) SCG-Net — побандовый Spectral Content Gate, обучающий почти бинарное разделение стиль/контент по частотным полосам.

II. Обзор литературы

A. Межсубъектное распознавание пЭМГ

База данных NinaPro [2] является де-факто стандартным бенчмарком для распознавания жестов по пЭМГ, предоставляя стандартизированные записи от 67 субъектов в нескольких упражнениях. Pizzolato и др. [16] сравнили классические и глубокие классификаторы на NinaPro, показав, что свёрточные сети могут сравниться с конвейерами ручных признаков при достаточном количестве обучающих данных. Голован и Зверева [9] установили воспроизводимый LOSO-бейзлайн на DB2 с 20 субъектами, сообщив лучший macro-F1 33,5% (CNN/LSTM BiGRU на необработанных сигналах) и 32,6% (SVM-RBF на TD-признаках), продемонстрировав, что межсубъектная вариабельность — а не ёмкость модели — является основным узким местом.

a) Классические методы ML.: Hudgins и др. [13] ввели канонический набор временных (TD) признаков — среднее абсолютное значение, пересечения нуля, изменения знака наклона и длина волны — для миоэлектрического распознавания паттернов. Phinyomark и др. [8] провели систематическую оценку наборов ЭМГ-признаков. Englehart и Hudgins [14] показали, что вейвлет-основанные время-частотные признаки с линейным дискриминантным анализом улучшают робастность. Scheme и Englehart [15] проанализировали разрыв между лабораторными и клиническими показателями миоэлектрического управления.

b) Глубокое обучение на необработанном ЭМГ.: Atzori и др. [1] применили CNN непосредственно к окнам пЭМГ на NinaPro. Côté-Allard и др. [6] предложили перенос обучения с CNN для межсессионного пЭМГ. Zhai и др. [17] представили самокалибрующуюся CNN-систему для адаптации к новым субъектам. Wei и др. [18] предложили многопоточные CNN, обрабатывающие параллельные временные разрешения.

c) Перенос обучения и доменная адаптация.: Du и др. [7] применили доменную адаптацию через минимизацию MMD для сглаживания сдвига распределений между обучающими и тестовыми субъектами. Ketyko и др. [19] оценили стратегии доменной адаптации для межсубъектного ЭМГ, обнаружив, что простая дообучка часто превосходит более сложные состязательные методы. Campbell и др. [5] проанализировали мешающие факторы — положение конечности, интенсивность сокращения, смещение электродов.

B. Частотная обработка биосигналов

a) EMD и VMD.: Huang и др. [20] ввели эмпирическую декомпозицию на моды (EMD), которая разлагает сигнал на собственные функции мод адаптивно. Rehman и Mandic [21] расширили EMD на многоканальные сигналы. Dragomiretskiy и Zosso [10] предложили вариационную декомпозицию на моды (VMD), формулирующую декомпозицию как задачу ограниченной оптимизации.

b) Вейвлетные и время-частотные методы.: Englehart и др. [22] показали, что признаки дискретного вейвлет-преобразования превосходят TD-признаки. Phinyomark и Scheme [23] обобщили частотные признаки для ЭМГ.

c) Обучаемые фильтрбанки.: Ravanelli и Bengio [11] ввели параметризованные Sinc-фильтры (SincNet) для распознавания дикторов. Этот подход был адаптирован для ЭЭГ [24]. Мы адаптируем эту идею для пЭМГ и дополнительно предлагаем развёрнутый VMD (UVMD), наследующий оптимизационную структуру VMD в дифференцируемом фреймворке.

C. Перенос стилей и доменная генерализация

a) Нормализация и манипуляция стилями.: Ioffe и Szegedy [25] ввели Batch Normalization; Ulyanov и др. [26] предложили Instance Normalization (IN), нормализующую каждый образец независимо. Huang и Belongie [27] продемонстрировали с AdaIN, что статистики признаков (среднее и дисперсия) кодируют «стиль». Эти наблюдения мотивируют наше исследование того, может ли нормализация на основе статистик удалить субъект-специфичный стиль в пЭМГ — наши результаты H3 показывают, что, в отличие от компьютерного зрения, жёсткая IN разрушает информацию о жестах.

b) Доменная генерализация.: Zhou и др. [12] предложили MixStyle, модуль смешивания статистик признаков между исходными доменами при обучении. Мы адаптируем MixStyle для работы побандово в пЭМГ. Sagawa и др. [28] ввели Group DRO; Arjovsky и др. [29] предложили IRM. Ganin и др. [30] ввели слой обращения градиента (GRL); наши эксперименты H4 показывают, что для пЭМГ это контрпродуктивно. Wang и др. [31] обобщили методы доменной генерализации, отличая их от подходов доменной адаптации [7], [19], предполагающих доступ к целевым данным. Наша работа относится к генерализации: данные тестового субъекта никогда не видны при обучении.

III. Данные и экспериментальный протокол

A. NinaPro DB2

Мы используем NinaPro Database 2 [2], включающую 40 здоровых субъектов, выполняющих жесты кисти, с записью пЭМГ 12 беспроводными электродами Delsys Trigno при частоте дискретизации 2000 Гц. Следуя

протоколу Голована и Зверевой [9], мы оцениваем на Exercise E1 (ID жестов 8–17, 10 хватательных жестов без отдыха), каждый повторяется 6 раз. Используется фиксированная подгруппа из 20 субъектов, выбранных для покрытия всего диапазона базы данных (ID субъектов 1–5, 11–15, 26–30, 36–40).

B. Предобработка

Необработанные сигналы пЭМГ сегментируются в окна по 200 мс (400 отсчётов при 2000 Гц) с перекрытием 50%. Применяется поканальная z-стандартизация по статистикам обучающей выборки (без утечки из тестовой). Полосовая фильтрация не применяется; фронтенд декомпозиции (Sinc или UVMD) выполняет роль обучаемого фильтра.

C. Протокол LOSO

Все эксперименты следуют строгой кросс-валидации с исключением одного субъекта (LOSO): в каждом фолде 19 субъектов используются для обучения (с 10% для валидации), а оставшийся — для тестирования. Мы сообщаем macro-F1 (основная метрика) и accuracy (вторичная), усреднённые по 20 фолдам со стандартным отклонением.

D. Статистическое тестирование

Все попарные сравнения используют критерий знаковых рангов Уилкоксона (двусторонний) на парных пер-субъектных F1-оценках. Мы сообщаем d Коэна (парный) как размер эффекта, количество побед/поражений по субъектам и бутстреп 95%-доверительные интервалы (10 000 ресэмплов) для среднего различия F1.

a) Поправка на множественные сравнения.: Вместо единой поправки Бонферрони по всем сравнениям ($k = 22$, чрезмерно консервативной) мы группируем тесты в семейства гипотез с общей нулевой гипотезой и применяем пошаговую процедуру Холма–Бонферрони [32] внутри каждого семейства:

- Семейство A ($k = 3$): Польза декомпозиции (H2 Sinc, H2 UVMD, H6 A→B).
- Семейство B ($k = 3$): Мягкая стилевая нормализация (H3 MixStyle, H6 B→C, H7 E→F).
- Семейство C ($k = 2$): Вред жёсткой нормализации (H3 Глобальная IN, H3 Побандовая IN).
- Семейство D ($k = 4$): Потери разделения (H4: контрастивная, GRL, MI, все вместе).
- Семейство E ($k = 3$): Варианты SCG-Net (H9 C vs. D, A vs. D, C vs. A).

Архитектурная абляция ($K = 4$ vs. 6 vs. 8) использует критерий Фридмана (поправка не требуется); сравнения H8 рассматриваются как дескриптивные (см. разд. VI-F).

Таблица I: Межсубъектная вариабельность по частотным полосам (40 субъектов). Норм. CV = CV относительной мощности (мощность в полосе / общая мощность).

Полоса (Гц)	CV (сырой)	Норм. CV	Критерий Фишера
20–100	2,55	0,20	0,079
100–200	2,34	0,28	0,077
200–350	2,31	0,46	0,073
350–500	2,30	0,70	0,069
500–700	2,41	1,15	0,063
700–1000	2,44	2,04	0,036

b) Конфирматорные и разведочные результаты.: Мы разделяем конфирматорные результаты ($p < 0{,}05$) и разведочные результаты ($p_{\cdot} < 0{,}05$, но $p \geq 0{,}05$). На протяжении всей работы p-значения помечены как p (скорректированные внутри семейства) или $p_{\cdot}$ во избежание неоднозначности.

IV. Спектральный анализ межсубъектной вариабельности

Для обоснования частотно-ориентированной обработки мы сначала характеризуем распределение межсубъектной вариабельности по спектру пЭМГ. Для каждого из 40 субъектов вычисляется спектральная плотность мощности (СПМ) методом Уэлча (БПФ 1024 точки, перекрытие 50%) и полоса Найквиста разбивается на шесть полос: 20–100, 100–200, 200–350, 350–500, 500–700 и 700–1000 Гц.

A. Коэффициент вариации

Для каждой полосы вычисляется коэффициент вариации (CV) относительной мощности между субъектами. Табл. I показывает, что нормированный CV монотонно растёт от 0,20 в полосе моторных единиц (20–100 Гц) до 2,04 выше 700 Гц — десятикратное соотношение. Ненормированный CV относительно постоянен (∼2,3–2,6), что указывает на то, что паттерн вариабельности проявляется только при учёте распределения мощности.

B. Дискриминантное отношение Фишера

Отношение Фишера (дисперсия между жестами / общая дисперсия субъектов) уменьшается с 0,079 (20–100 Гц) до 0,036 (700–1000 Гц), подтверждая, что высокочастотные полосы являются одновременно более вариабельными между субъектами и менее дискриминативными между жестами (табл. I).

На рис. 1 визуализирован этот градиент: после нормализации общей мощностью межсубъектный CV монотонно возрастает от полосы моторных единиц к высокочастотному хвосту, тогда как ненормированный CV остаётся постоянным. На рис. 2 показана причина: наложение СПМ для каждого жеста демонстрирует, что «веер» индивидуальных кривых расходится

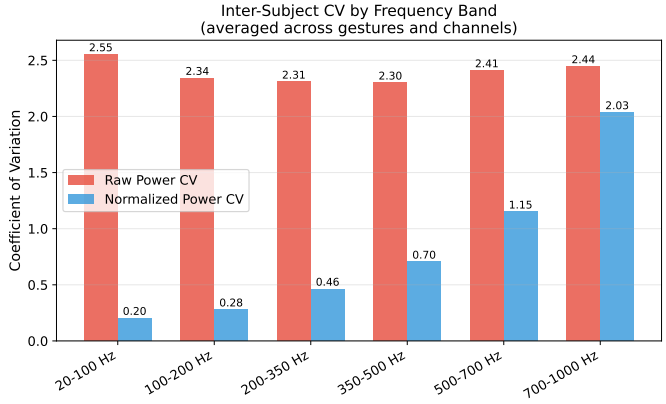

Рис. 1: Межсубъектный коэффициент вариации (CV) по частотным полосам, усреднённый по 10 жестам и 12 каналам (40 субъектов). Красный: CV сырой мощности (плоский ∼2,3–2,6). Синий: нормированный CV (мощность в полосе / общая мощность) — десятикратный рост от 20–100 Гц до 700–1000 Гц.

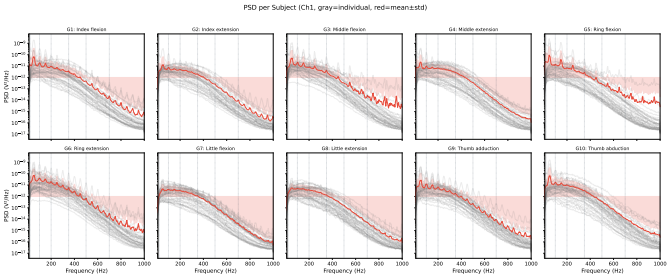

Рис. 2: СПМ Уэлча по жестам (канал 1, 40 субъектов). Серые линии — индивидуальные субъекты; красная — среднее ± std. Межсубъектная огибающая расширяется неравномерно по спектру, что мотивирует побандовую обработку.

неравномерно по спектру, с наибольшим разбросом на высоких частотах.

Рис. 3 детализирует этот паттерн по отдельным жестам: нормированный CV монотонно растёт от нижних к верхним полосам для каждого из 10 жестов, что подтверждает универсальность наблюдения.

Следствие. Монолитная модель, обрабатывающая все частоты одинаково, вынуждена искать компромисс между подавлением высокочастотного субъектного шума и сохранением низкочастотной информации о жестах. Частотная декомпозиция позволяет побандовую обработку, применяя более сильную нормализацию там, где вариабельность максимальна. В следующем разделе мы описываем конвейер обработки, спроектированный на основе этого наблюдения.

V. Предлагаемый метод

Наш конвейер (рис. 4) обрабатывает окно необработанного пЭМГ $\mathbf{X} \in \mathbb{R}^{T\times C}$ ($T = 400$ отсчётов, $C = 12$

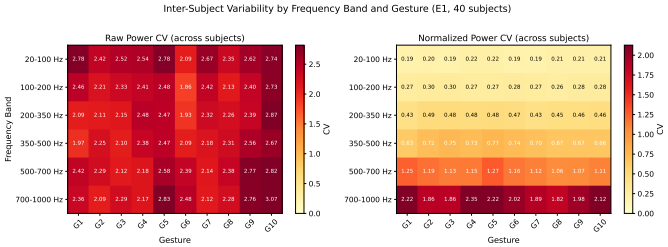

Рис. 3: Тепловая карта межсубъектного CV по частотным полосам и жестам (40 субъектов). Слева: CV сырой мощности (равномерно высокий). Справа: нормированный CV — монотонный рост от низких частот к высоким для каждого жеста.

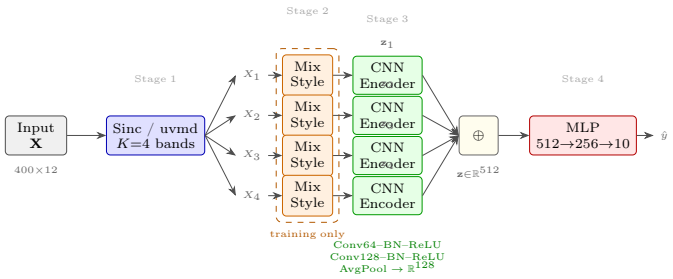

Рис. 4: Архитектура предлагаемого частотно-ориентированного конвейера. Этап 1: декомпозиция входного сигнала на $K{=}4$ частотных поддиапазона (Sinc или uvmd). Этап 2: побандовый MixStyle (только при обучении; ноль параметров) смешивает статистики между субъектами. Этап 3: независимое кодирование каждого поддиапазона CNN-энкодером ($\mathbf{z}_k \in \mathbb{R}^{128}$). Этап 4: классификация конкатенированного представления $\mathbf{z} \in \mathbb{R}^{512}$ MLP-головой.

каналов) в четыре этапа:

A. Этап 1: Частотная декомпозиция

Мы декомпозируем $\mathbf{X}$ на $K = 4$ поддиапазонных сигнала $\{\mathbf{X}_k\}_{k=1}^{K}$, каждый $\in \mathbb{R}^{T\times C}$, используя один из двух фронтендов:

a) Фиксированный Sinc-фильтрбанк.: Четыре полосовых Sinc-фильтра с фиксированными частотами среза разбивают полосу Найквиста на равные поддиапазоны. Для фильтра k с полосой пропускания $[f_k^{\mathrm{lo}}, f_k^{\mathrm{hi}}]$:

$$h_k[n] = 2f_k^{\mathrm{hi}}\,\mathrm{sinc}(2f_k^{\mathrm{hi}}n) - 2f_k^{\mathrm{lo}}\,\mathrm{sinc}(2f_k^{\mathrm{lo}}n) \qquad (1)$$

с окном Хэмминга, применяемая свёрткой к каждому каналу независимо. Частоты среза фиксированы: $[0; 0{,}125; 0{,}25; 0{,}375; 0{,}5]$ (нормированная частота), что соответствует четырём равным полосам. Фронтенд добавляет только 8 параметров.

b) Развёрнутый VMD (UVMD).: Мы разворачиваем $L = 8$ итераций ADMM-обновления для VMD [10] в дифференцируемый нейросетевой блок. Обучаемые параметры:

- $\boldsymbol{\alpha} \in \mathbb{R}^{L\times K}$: штраф на полосу пропускания (по итерациям и модам),
- $\boldsymbol{\tau} \in \mathbb{R}^{L}$: шаг Лагранжиана (по итерациям),
- $\boldsymbol{\omega} \in \mathbb{R}^{K}$: центральные частоты (инициализированы равномерно: $[0{,}05; 0{,}18; 0{,}32; 0{,}45]$).

На каждой ADMM-итерации l для моды k спектральное обновление:

$$\hat{u}_k^{(l)}(\xi) = \frac{\hat{r}_k(\xi)}{1 + \alpha_{l,k}(\xi - \omega_k)^2} \tag{2}$$

где $\hat{r}_k$ — остаток после удаления всех остальных мод. Штраф на спектральное перекрытие $\mathcal{L}_{\text{overlap}} = \sum_{j\neq k} \exp(-10(\omega_j - \omega_k)^2)$ стимулирует частотное разнообразие. Фронтенд добавляет 44 параметра ($\boldsymbol{\alpha}$: 32, $\boldsymbol{\tau}$: 8, $\boldsymbol{\omega}$: 4).

B. Этап 2: Побандовый энкодер

Каждый поддиапазон $\mathbf{X}_k$ независимо кодируется 1D-CNN с общей архитектурой:

$$\mathbf{z}_k = \text{AvgPool}\big(\text{ReLU}\big(\text{BN}\big(\text{Conv}_{128}\big(\text{ReLU}\big(\text{BN}\big(\text{Conv}_{64}(\mathbf{X}_k)\big)\big)\big)\big)\big)\big) \tag{3}$$

где Conv_d обозначает $\text{Conv1d}(C, d, \cdot)$ с ядрами 5 и 3 соответственно, а AvgPool — глобальное адаптивное среднее. Каждый энкодер отображает $\mathbb{R}^{T\times C} \to \mathbb{R}^{128}$; четыре энкодера дают $\mathbf{z} = [\mathbf{z}_1; \ldots; \mathbf{z}_4] \in \mathbb{R}^{512}$.

C. Этап 3: Побандовый MixStyle

Только при обучении мы применяем MixStyle [12] независимо к каждому поддиапазону до кодирования. Для поддиапазона k и образца i в мини-батче:

$$\mu_k^{(i)} = \mathbb{E}_t[\mathbf{X}_k^{(i)}], \quad \sigma_k^{(i)} = \sqrt{\text{Var}_t[\mathbf{X}_k^{(i)}] + \epsilon} \tag{4}$$

$$\tilde{\mathbf{X}}_k^{(i)} = \frac{\mathbf{X}_k^{(i)} - \mu_k^{(i)}}{\sigma_k^{(i)}} \tag{5}$$

$$\lambda \sim \text{Beta}(\alpha, \alpha), \quad j = \text{shuffle}(i) \tag{6}$$

$$\tilde{\mu}_k = \lambda\mu_k^{(i)} + (1-\lambda)\mu_k^{(j)}, \quad \tilde{\sigma}_k = \lambda\sigma_k^{(i)} + (1-\lambda)\sigma_k^{(j)} \tag{7}$$

$$\hat{\mathbf{X}}_k^{(i)} = \tilde{\sigma}_k \cdot \tilde{\mathbf{X}}_k^{(i)} + \tilde{\mu}_k \tag{8}$$

с $\alpha = 0{,}1$ и вероятностью применения $p = 0{,}5$. Этот модуль имеет ноль обучаемых параметров: он только манипулирует статистиками. Ключевое отличие от глобального MixStyle — побандовое применение, позволяющее разные уровни стилевых возмущений в каждом частотном диапазоне.

a) Адаптивный побандовый MixStyle (H8).: Мы расширяем фиксированный модуль, делая α и p обучаемыми для каждой полосы:

$$\alpha_k = \text{softplus}(\theta_k^{\alpha}) + \epsilon, \quad p_k = \sigma(\theta_k^{p}) \tag{9}$$

где $\theta_k^{\alpha}, \theta_k^{p}$ — необработанные параметры, инициализированные для $\alpha_k = 0{,}1$, $p_k = 0{,}5$. Выход — мягкое смешивание оригинала и стилизованного сигнала: $\hat{\mathbf{X}}_k = p_k \cdot \tilde{\mathbf{X}}_k^{\text{mixed}} + (1-p_k)\cdot \mathbf{X}_k$, что обеспечивает полную дифференцируемость через репараметризованную выборку из Beta-распределения. Это добавляет всего $2K = 8$ обучаемых параметров.

Таблица II: Число параметров по вариантам модели.

Вариант	Всего	Фронтенд	Примечание
A: Raw CNN (K=1)	64 586	0	Один энкодер
B: Sinc FB (K=4)	249 874	8	4 энкодера
C: Sinc + MixStyle	249 874	8	+0 для MixStyle
D: Sinc + MS + CS	172 130	8	Контент/стиль
E/F: UVMD (K=4)	249 910	44	Обучаемая декомп.
G: Sinc + Адапт. MS	249 882	16	+8 для α_k, p_k
H: UVMD + Адапт. MS	249 918	52	+8 для α_k, p_k
SCG-A: Sinc + SCG	136 974	12	+4 для γ_k
SCG-B: UVMD + SCG + Адв	172 365	48	+4 γ_k, +35K адв.

b) Spectral Content Gate (H9).: Вместо аугментации стиля (MixStyle), Spectral Content Gate (SCG) обучается его селективному удалению. Для каждой полосы k обучаемый гейт $\gamma_k = \sigma(\theta_k^{\gamma}) \in [0, 1]$ смешивает нормализованный (без стиля) и исходный (со стилем) вход:

$$\hat{\mathbf{X}}_k = \gamma_k \cdot \frac{\mathbf{X}_k - \mu_k}{\sigma_k} + (1-\gamma_k)\cdot \mathbf{X}_k \tag{10}$$

При $\gamma_k \to 1$ полоса k проходит полную Instance Normalization; при $\gamma_k \to 0$ исходный сигнал сохраняется. Это добавляет всего $K = 4$ обучаемых параметра. Ключевое отличие от MixStyle: SCG — детерминистический модуль, активный при инференсе, а не обучающая аугментация.

D. Этап 4: Классификатор

Двуслойный MLP отображает $\mathbf{z} \in \mathbb{R}^{512}$ в логиты классов: 512 $\to$ 256 (ReLU, dropout $p = 0{,}3$) $\to$ 10 (softmax).

a) Обучение.: Суммарная функция потерь:

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \lambda_{\text{ov}} \cdot \mathcal{L}_{\text{overlap}} \tag{11}$$

с $\lambda_{\text{ov}} = 0{,}01$ (только для UVMD; ноль для Sinc). Используется Adam ($\text{lr} = 10^{-3}$), ReduceLROnPlateau (фактор 0,5, терпение 5) и ранняя остановка (терпение 15) до 80 эпох.

b) Размер модели.: Табл. II суммирует число параметров. Фронтенд декомпозиции добавляет пренебрежимо мало (8–44 параметра); основные затраты — четыре побандовых энкодера (116 000). MixStyle добавляет ноль параметров.

VI. Эксперименты и результаты

Экспериментальная оценка строится вокруг центрального противопоставления: глобальная инвариантность (удаление стиля из всех частот, состязательное разделение) vs. частотно-селективная обработка (декомпозиция + побандовая аугментация). Мы сначала показываем, что глобальные подходы вредят (разд. VI-C), затем количественно оцениваем вклад каждого компонента частотно-селективного конвейера (разд. VI-D), и наконец проверяем, обучается ли

сеть частотному градиенту вариабельности самостоятельно (разд. VI-F and VI-G). Табл. III суммирует все проверенные гипотезы; статистические детали — в разд. III-D.

A. H2: Частотная декомпозиция vs. необработанный сигнал

Табл. IV показывает, что декомпозиция на $K = 4$ полосы устойчиво превосходит обработку необработанного сигнала. Sinc-фильтрбанк и UVMD дают $+2{,}1$–$2{,}3$ п. п. F1 со средним размером эффекта ($d \approx 0{,}67$–$0{,}68$). В рамках Семейства A (декомпозиция, $k = 3$) оба сравнения достигают значимости после поправки Холма ($p < 0{,}02$), а контролируемая абляция H6 (разд. VI-D) независимо подтверждает эффект ($p < 0{,}003$). Sinc и UVMD статистически неразличимы ($\Delta = +0{,}24$ п. п., $p = 0{,}50$), что мотивирует использование более простого Sinc-фронтенда в последующих экспериментах.

Примечание: ранние и поздние серии экспериментов различаются размером батча (64 vs. 512); абсолютные F1 между таблицами не сопоставимы напрямую (см. разд. VII-B).

B. H3: Побандовая стилевая нормализация

Установив, что декомпозиция помогает, мы проверяем, можно ли дополнительно улучшить качество побандовой нормализацией стилей. Табл. V обнаруживает выраженную асимметрию: мягкая нормализация (MixStyle) даёт $+1{,}67$ п. п. ($d = 0{,}54$, разведочный), тогда как жёсткая (Instance Normalization) катастрофически ухудшает качество: $-7{,}0$ п. п. для глобальной IN ($d = -1{,}13$) и $-8{,}5$ п. п. для побандовой ($d = -1{,}36$), оба $p < 0{,}002$.

Адаптивный вариант IN, обучающий силу нормализации γ_k для каждой полосы, даёт ценную диагностику: он сходится к $\gamma_1 = 0{,}027$ (низкие частоты) против $\gamma_4 = 0{,}38$ (высокие частоты) — соотношение 14:1, независимо подтверждающее вывод H1.

C. Отрицательные результаты: что не работает

Прежде чем перейти к основной абляции, мы суммируем ключевые отрицательные результаты, определившие направление исследования.

a) Жёсткая Instance Normalization вредит (табл. V).: Глобальная IN теряет $-7{,}0$ п. п. ($p < 0{,}002$), побандовая IN — $-8{,}5$ п. п.. IN удаляет все статистики первого и второго порядка, включая поканальные амплитудные паттерны, несущие информацию о жесте.

b) Явное разделение контента и стиля вредит (табл. VI).: Добавление состязательной (GRL), MI-минимизирующей или контрастивной потерь для разделения контента и стиля ухудшает качество на $-2{,}6$ – $-4{,}3$ п. п. ($p < 0{,}01$). Состязательная потеря ухудшает

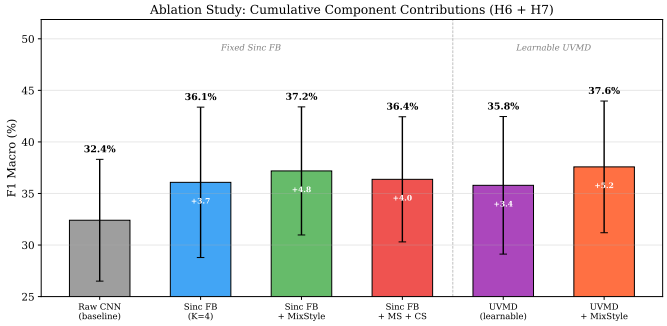

Рис. 5: Вклад компонентов конвейера (абляция H6 + H7). Слева: фиксированный Sinc-фронтенд; справа: обучаемый UVMD. Числа внутри столбцов — суммарное улучшение над бейзлайном Raw CNN. Декомпозиция вносит наибольший вклад ($+3{,}4$–$3{,}7$ п. п.); MixStyle добавляет дополнительные $+1{,}1$–$1{,}8$ п. п..

каждого субъекта (0/20 улучшений, $d = -2{,}16$). В нашей постановке контент жеста и стиль субъекта содержат достаточно общей информации; принудительное их разделение разрушает представление.

c) Усложнение архитектуры не помогает.: Увеличение числа полос ($K = 6, 8$), добавление SE-attention и GroupDRO не улучшают качество: критерий Фридмана по шести вариантам $\chi^2 = 2{,}94$, $p = 0{,}71$. Простейшая архитектура ($K = 4$, без дополнений) остаётся лучшей.

Эти результаты определили конструкцию итогового конвейера: неявная стилевая робастность через MixStyle предпочтительнее явного разделения, а $K = 4$ достаточно.

D. Единая абляция (чистая атрибуция компонентов)

Для изоляции вкладов отдельных компонентов мы фиксируем единую архитектуру и варьируем один компонент за шаг (табл. VII). Серия абляции использует batch_size = 512, что влияет на абсолютные значения F1 по сравнению с ранними экспериментами (bs=64); см. разд. VII-B.

Абляция подтверждает, что частотная декомпозиция — наибольший отдельный вклад в конвейер: она добавляет $+3{,}7$ п. п. с большим размером эффекта (табл. VII). Побандовый MixStyle добавляет ещё $+1{,}1$ п. п.; направление устойчиво (18 из 20 субъектов улучшаются), но индивидуально не достигает значимости после поправки. Добавление контент/стиль голов ухудшает качество, что согласуется с отрицательными результатами явного разделения (разд. VI-C). Итог: лучший вариант — Sinc + побандовый MixStyle (рис. 5).

E. H7: Универсальность побандового MixStyle

Помогает ли MixStyle только с фиксированной декомпозицией, или он агностичен к фронтенду? Проверяем на обучаемом UVMD (табл. VIII).

На обучаемом UVMD-фронтенде побандовый MixStyle добавляет $+1{,}8$ п. п. с большим размером

Таблица III: Сводка цепочки гипотез. NinaPro DB2 E1, 20 субъектов, строгий LOSO. p: скорректировано внутри семейства гипотез. Статус: К = конфирматорный ($p < 0{,}05$), Р = разведочный (только $p_{\cdot} < 0{,}05$), О = отвергнут, Д = дескриптивный. Метки семейств: A=декомпозиция, B=мягкий стиль, C=жёсткая норм., D=разделение, E=SCG-Net. †H2–H4: batch=64; H6–H9: batch=512 (см. разд. VII-B).

#	Гипотеза	Ключевой вопрос	Семейство	Статус	ΔF1	$p_{\cdot}$	p
H1	Спектр. вариаб.	Зависит ли межсубъектная вариабельность от частоты?	—	Д	—	—	—
H2†	Декомпозиция	Превосходит ли декомпозиция необработанный сигнал?	A	К	+2,3 п. п.	0,007	<0,02
H3†	Стилевая норм.	Помогает ли побандовый MixStyle?	B	Р	+1,7 п. п.	0,04	0,08
		Помогает ли Instance Norm?	C	О (К)	−7,0 п. п.	<0,001	<0,002
H4†	Разделение	Помогает ли явное разделение контент/стиль?	D	О (К)	−2,6 п. п.	<0,001	<0,004
H6	Абляция	Вклад декомпозиции (A→B)	A	К	+3,7 п. п.	<0,001	<0,003
		Вклад MixStyle (B→C)	B	Р	+1,1 п. п.	0,07	0,07
H7	UVMD+MixStyle	Агностичен ли MixStyle к фронтенду?	B	К	+1,8 п. п.	0,003	<0,01
H8	Адапт. MixStyle	Обучается ли сеть градиенту H1?	—	Д‡	+0,97 п. п.	0,064	—
H9	SCG-Net	Превосходит ли побандовый гейт равномерную IN?	E	К	+6,86 п. п.	<0,001	<0,001

‡Статус H8 — Д (дескриптивный): основное свидетельство — градиент обученных параметров (Spearman $\rho = 0{,}78$), а не ΔF1.
Дополнительно проверено увеличение числа полос ($K = 6$, 8), SE-attention, GroupDRO — без значимых улучшений (Фридман $p = 0{,}71$).

Таблица IV: H2: Сравнение декомпозиций (20 субъектов, LOSO).

Фронтенд	F1 (%)	Δ vs. raw	d
Без (raw)	34,90 ± 8,16	—	—
Sinc FB (K=4)	37,00 ± 7,56	+2,10	0,67
UVMD (K=4)	37,24 ± 7,75	+2,34	0,68

Таблица V: H3: Сравнение стилевой нормализации (20 субъектов, LOSO). Бейзлайн: Sinc FB (K=4), без нормализации.

Нормализация	F1 (%)	Δ	d
Без (бейзлайн)	36,28 ± 7,81	—	—
Побандовый MixStyle	37,95 ± 7,22	+1,67	0,54
Адаптивная IN (γ_k)	36,90 ± 6,98	+0,62	0,24
Глобальная IN	29,29 ± 5,30	−6,99	−1,13
Побандовая IN	27,75 ± 4,29	−8,53	−1,36

эффекта ($d = 0{,}84$), и этот результат является конфирматорным после поправки Холма (табл. VIII). На фиксированном Sinc эффект устойчив по направлению (+1,1 п. п., 18/20 субъектов), но остаётся разведочным. Это различие может объясняться тем, что адаптивное размещение частот UVMD создаёт поддиапазоны, в которых статистики стилей более информативны.

Два фронтенда статистически неразличимы по итоговому F1: разница минимальна, а выбор между ними не влияет на основной вывод. Воспроизведение лучшего варианта при batch_size = 64 подтверждает робастность: результат не меняется ($p = 0{,}67$; см. разд. VII-B).

а) Обученные частоты UVMD.: Рис. 7 показывает обученные центральные частоты, наложенные на спектр мощности ЭМГ. Начиная с равномерной инициализации [100, 367, 633, 900] Гц, UVMD сходится к

Таблица VI: Влияние вспомогательных потерь разделения контента/стиля (20 субъектов). Бейзлайн: Sinc FB + MixStyle + CS-головы.

Потеря	F1 (%)	Δ	d	p
Без (бейзлайн)	39,19 ± 6,34	—	—	—
+ Контрастивная	38,99 ± 5,95	−0,19	−0,14	1,00
+ Состязательная (GRL)	36,60 ± 5,99	−2,58	−2,16	<0,004
+ MI-минимизация	35,29 ± 7,28	−3,89	−0,97	<0,01
+ Все вместе	34,89 ± 7,18	−4,30	−1,04	<0,01

Таблица VII: H6: Единая абляция (20 субъектов, batch=512, LOSO). Каждый шаг добавляет ровно один компонент. Стат. тесты: Уилкоксон с поправкой Холма внутри семейств гипотез (A, B).

	Компоненты	F1 (%)	IQR	Δ	d	p	↑ / ↓
A	Raw CNN	32,40 ± 5,91	8,9	—	—	—	—
B	+ Sinc FB	36,08 ± 7,29	10,4	+3,68	1,25	<0,003	18/2
C	+ MixStyle	37,19 ± 6,21	8,5	+1,11	0,42	0,07*	18/2
D	+ CS-головы	36,37 ± 6,07	8,8	−0,82	−0,62	0,34	5/15

*Разведочный: не достигает значимости в рамках Семейства B.

[87±4, 385±4, 671±4, 889±9] Гц по всем 20 субъектам (std < 10 Гц), указывая на универсальную, субъект-независимую частотную декомпозицию.

F. H8: Адаптивный побандовый MixStyle

Обучается ли сеть частотно-зависимой стилевой аугментации, предсказанной H1, или фиксированные $\alpha = 0{,}1$, $p = 0{,}5$ уже оптимальны? Мы заменяем фиксированный побандовый MixStyle адаптивным вариантом (ур. (9)) на обоих фронтендах: Sinc (вариант G) и UVMD (вариант H). Параметры MixStyle получают 10× базовую скорость обучения для сходимости за 80 эпох. В качестве абляции мы также тестируем варианты с обращённым градиентом (I, J), где обученные α_k, p_k назначаются полосам в обратном порядке (зна-

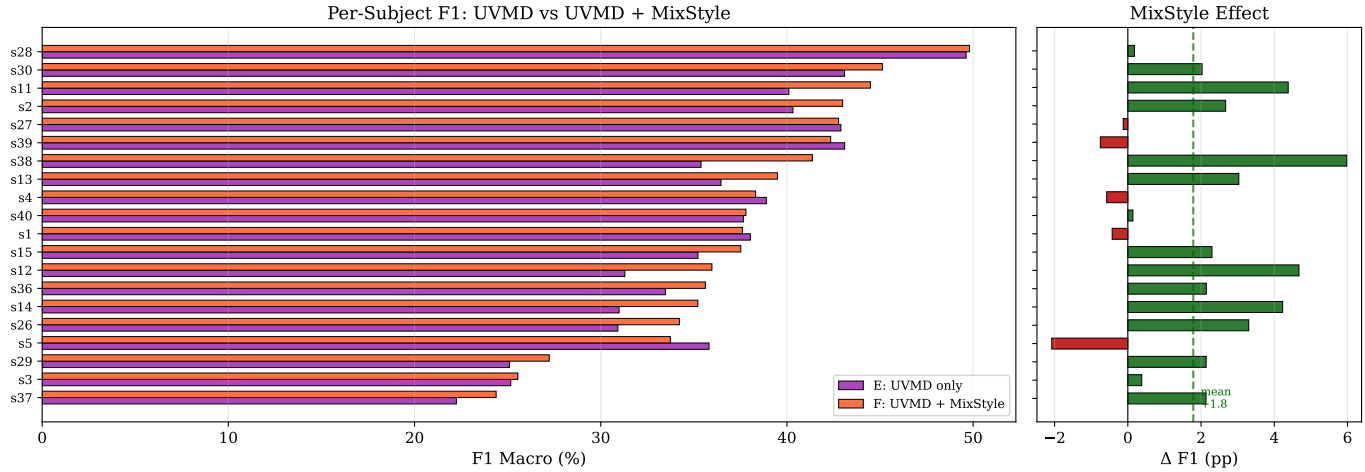

Рис. 6: Пер-субъектный F1 для UVMD (фиолетовый) и UVMD+MixStyle (оранжевый), отсортирован по убыванию F1 (слева). Справа: пер-субъектный прирост ΔF1 от MixStyle. 16 из 20 субъектов получают положительный прирост (зелёные столбцы), средний эффект +1,8 п. п..

Таблица VIII: H7: UVMD + MixStyle (20 субъектов, batch=512, LOSO; вариант F воспроизведён при batch=64, $p = 0{,}67$). E→F: $p < 0{,}01$ (Семейство B, конфирматорный).

	Фронтенд + стиль	F1 (%)	Δ	d	$p_.$
E	UVMD	35,79 ± 6,67	—	—	—
F	UVMD + MixStyle	37,58 ± 6,39	+1,79	0,84	0,003
	Сравнение фронтендов:				
B	Sinc FB	36,08 ± 7,29	—	−0,16	0,78
E	UVMD	35,79 ± 6,67			
C	Sinc + MS	37,19 ± 6,21	+0,39	0,25	0,43
F	UVMD + MS	37,58 ± 6,39			

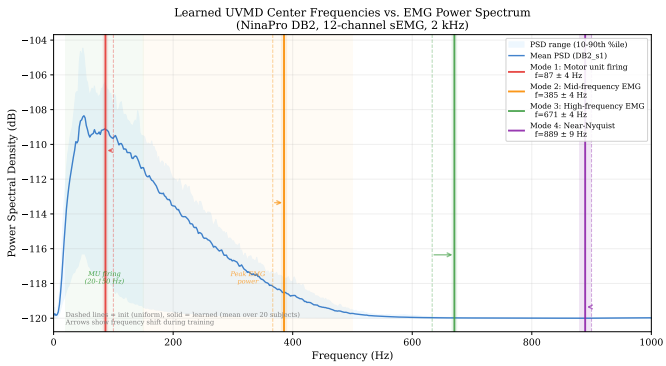

Рис. 7: Обученные центральные частоты UVMD (сплошные линии, среднее по 20 субъектам) на фоне СПМ ЭМГ (репрезентативный субъект). Штриховые линии: начальные (равномерные) частоты. Стрелки показывают направление адаптации.

чения полосы 4 присваиваются полосе 1 и наоборот), чтобы проверить каузальную значимость конкретного распределения по полосам.

Табл. IX показывает, что правильный порядок полос превосходит обращённый на обоих фронтендах. Эффект сильнее на UVMD (+0,97 п. п., Уилкоксон $p = 0{,}064$, 15/20 побед по субъектам) по сравнению с Sinc (+0,24 п. п., $p = 0{,}67$). Однако основной результат — не разница F1, а градиент обученных параметров (табл. X).

Таблица IX: H8: Адаптивный побандовый MixStyle (20 субъектов, batch=512, LOSO). G/H — обучаемые α_k, p_k; I/J — абляция обращённого градиента (обученные значения в неправильном порядке полос).

	Фронтенд + стиль	F1 (%)	Acc (%)	ΔF1 vs. обр.
G	Sinc + Адапт. MS	35,56 ± 7,05	37,23 ± 6,59	+0,24
I	Sinc + Обращ. MS	35,32 ± 7,32	36,97 ± 6,62	—
H	UVMD + Адапт. MS	34,42 ± 6,91	36,79 ± 6,29	+0,97
J	UVMD + Обращ. MS	33,46 ± 6,40	35,53 ± 6,02	—

Таблица X: Обученные параметры адаптивного MixStyle (среднее ± std по 20 LOSO-фолдам). Инициализация: $\alpha_k = 0{,}1$, $p_k = 0{,}5$ для всех полос.

Полоса	G (Sinc)		H (UVMD)	
k	α_k	p_k	α_k	p_k
1 (НЧ)	1,62 ± 0,10	<0,001	1,30 ± 0,30	0,018 ± 0,027
2	0,89 ± 0,11	<0,001	1,08 ± 0,24	0,014 ± 0,022
3	7,80 ± 1,24	0,010 ± 0,002	3,04 ± 1,45	0,036 ± 0,029
4 (ВЧ)	16,28 ± 2,43	0,040 ± 0,006	2,62 ± 1,36	0,046 ± 0,051
Отношение $k = 4/k = 1$	10,0×	>100×	2,0×	2,5×
Spearman ρ	0,775 ($p < 10^{-16}$)		0,347 ($p = 0{,}002$)	

Обученные параметры демонстрируют чёткий монотонный градиент (табл. X): сеть, оптимизированная исключительно по классификационной потере, самостоятельно приходит к частотно-селективной стратегии. Она фактически отключает смешивание стилей в низкочастотных полосах ($p_k < 0{,}001$ на Sinc), где доминирует информация о жесте, и избирательно включает его в высокочастотных ($p_4 = 0{,}040$), где доминирует субъектный шум. На Sinc-фронтенде отношение α_4/α_1

Таблица XI: H9: Результаты SCG-Net (20 субъектов, batch=512, LOSO). Вариант C — основная архитектура; A добавляет состязательную потерю по субъектам; D использует фиксированный $\gamma_k = 1$ (равномерная Instance Norm, абляция).

	Конфигурация	F1 (%)	Acc (%)	ΔF1 vs. D
SCG-C	Sinc + SCG (обуч. γ_k)	35,65 ± 6,60	37,39 ± 6,07	+6,86
SCG-A	Sinc + SCG + Состяз.	34,75 ± 5,92	36,17 ± 5,82	+5,97
SCG-B	UVMD + SCG + Состяз.	34,56 ± 5,97	36,01 ± 5,65	+5,77
SCG-D	Sinc + полная IN ($\gamma_k = 1$ фикс.)	28,79 ± 4,09	29,32 ± 3,94	—

Таблица XII: Обученные значения SCG-гейта γ_k (среднее ± std по 20 LOSO-фолдам). Инициализация: $\gamma_k = 0{,}5$ для всех полос.

Полоса k	SCG-C (Sinc)	SCG-A (Sinc + Состяз.)
1 (НЧ)	<0,001	<0,001
2	<0,001	<0,001
3	<0,001	0,001 ± 0,001
4 (ВЧ)	0,998 ± 0,002	0,910 ± 0,184
Spearman ρ	0,433 ($p < 10^{-4}$)	0,774 ($p < 10^{-16}$)

составляет 10×, что зеркально воспроизводит десятикратный градиент нормированного CV из спектрального анализа (Spearman $\rho = 0{,}775$).

Это свидетельство является дескриптивным: параметры оптимизируются совместно со всеми весами, а абляция с обращённым порядком полос показывает лишь небольшое и незначимое преимущество правильного порядка. Тем не менее сам факт того, что сеть независимо обучает ту же частотную структуру, которая была обнаружена аналитически, является нетривиальным.

G. H9: Spectral Content Gate Network (SCG-Net)

Можно ли закодировать наблюдение H1 непосредственно как архитектурный приор, а не обучающую аугментацию? SCG-Net заменяет MixStyle на Spectral Content Gate (ур. (10)): побандовый обучаемый гейт γ_k, смешивающий нормализованный (без стиля) и исходный вход, добавляя всего $K = 4$ параметра.

Табл. XI показывает, что SCG-Net (вариант C) достигает 35,65% F1, значимо превосходя равномерную Instance Normalization (вариант D, 28,79%) на +6,86 п. п. ($p < 0{,}001$, Семейство E, 18/20 побед по субъектам). Обученные значения гейта (табл. XII) демонстрируют почти бинарное разделение: $\gamma_{1-3} < 0{,}001$ (сохранение всего стиля в низкочастотных полосах) и $\gamma_4 = 0{,}998$ (удаление всего стиля в высшей полосе). Этот паттерн согласуется с наблюдением H1, хотя он обучен в рамках той же архитектурной платформы, а не является полностью независимой валидацией.

Состязательная потеря по субъектам (вариант A) незначительно снижает качество по сравнению с SCG без неё (C), что согласуется с выводом H4 о том, что состязательное разделение может вредить классификации пЭМГ. Критерий Уилкоксона подтверждает значимость этого различия ($p = 0{,}048$, 12/20 побед C над A).

Таблица XIII: Сравнение с опубликованными бейзлайнами (LOSO, 20 субъектов, NinaPro DB2 E1). Опубликованные результаты из [9]. †Воспроизведение при batch=64.

Метод	Признаки	F1 (%)
CNN/LSTM BiGRU [9]	Raw ЭМГ	33,5 ± 8,0
Simple CNN [9]	Raw ЭМГ	33,3 ± 9,1
SVM-RBF [9]	TD-призн.	32,6 ± 7,7
SVM-Linear [9]	TD-призн.	32,5 ± 9,4
Наш: Sinc + MixStyle (C)	Raw ЭМГ	37,19 ± 6,21
Наш: UVMD + MixStyle (F)	Raw ЭМГ	37,69 ± 6,85†

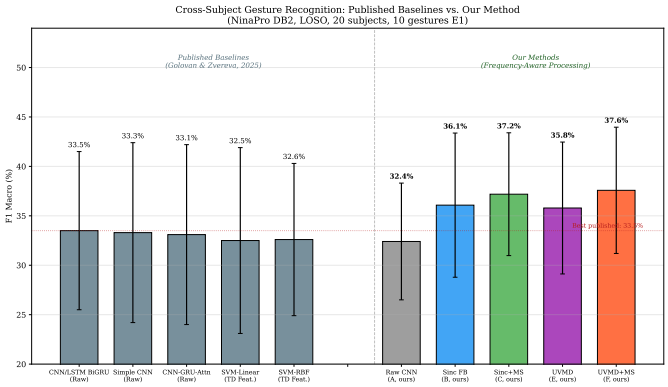

Рис. 8: Сравнение с опубликованными бейзлайнами (серые) и вариантами нашего конвейера (цветные). Пунктирная линия: лучший опубликованный результат (33,5%). Каждый вариант последовательно добавляет компоненты: декомпозиция, MixStyle, обучаемый фронтенд.

H. Сравнение с опубликованными бейзлайнами

Табл. XIII сравнивает наши результаты с опубликованными LOSO-бейзлайнами Голована и Зверевой [9]. Наш лучший метод (UVMD+MixStyle) даёт 37,7% F1 (37,69% при bs=64, 37,58% при bs=512) по сравнению с предыдущим лучшим результатом (CNN/LSTM BiGRU, 33,5%). Отметим, что сравнение проводится между различными архитектурами и режимами обучения; парный статистический тест невозможен, так как бейзлайны обучались отдельно.

I. Кому помогает MixStyle?

Рис. 9 показывает, что выигрыш от MixStyle отрицательно коррелирует с базовым F1 для Sinc-фронтенда ($r = -0{,}56$, $p = 0{,}01$): слабые субъекты выигрывают больше, сильные — меньше. Это предполагает, что MixStyle действует как регуляризатор, помогая прежде всего субъектам, чьи сигналы наиболее отклоняются от обучающего распределения.

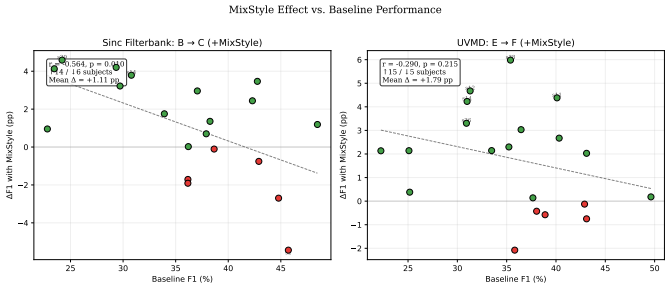

Рис. 9: Пер-субъектный прирост F1 от MixStyle vs. базовый F1. Слева: Sinc FB (B→C), значимая отрицательная корреляция. Справа: UVMD (E→F), аналогичный тренд.

VII. Обсуждение

A. Центральный вывод: частотная селективность, а не глобальная инвариантность

Совокупность результатов указывает на один ключевой вывод: в пЭМГ субъект-инвариантность достигается не через глобальную нормализацию и не через разделение контента и стиля, а через частотно-селективную обработку, где низкочастотные полосы сохраняются, а высокочастотные — нормализуются или рандомизируются.

Это подтверждается с трёх независимых сторон:

- Аналитически: спектральный анализ показывает десятикратный градиент межсубъектной вариабельности от низких к высоким частотам, при этом отношение Фишера движется в противоположном направлении.
- Через обучение: адаптивный MixStyle и SCG-Net, оптимизированные только по классификационной потере, независимо обучают монотонные градиенты параметров, воспроизводящие аналитическое наблюдение.
- Через отрицательные результаты: глобальные подходы — равномерная IN (-7–$8{,}5$ п. п.), состязательное разделение ($-2{,}6$–$4{,}3$ п. п.) — разрушают информацию о жестах, потому что амплитудный паттерн по 12 электродам одновременно кодирует жест и физиологию субъекта.

Различие между аугментацией и удалением стиля также согласуется с этим выводом: MixStyle (интерполяция статистик) сохраняет структуру распределения и увеличивает разнообразие обучения, тогда как SCG-Net и IN (удаление статистик) менее эффективны, даже будучи частотно-селективными.

B. Конфаунд размера батча

Ранние эксперименты использовали batch_size = 64, абляция — 512. Абсолютные значения F1 различаются между сериями (напр., Raw CNN: 34,9% при bs=64 vs. 32,4% при bs=512), поэтому результаты разных серий не сопоставимы напрямую. Для проверки робастности мы воспроизвели лучший вариант (UVMD+MixStyle) при bs=64: 37,69% $\pm$ 6,85 — статистически не отличается от результата при bs=512 (37,58% $\pm$ 6,39; Уилкоксон $p = 0{,}67$).

C. Ограничения

1) Один датасет и упражнение. Все результаты на NinaPro DB2 E1 (10 жестов, 12 каналов, 2000 Гц). Генерализация на другие базы и аппаратуру не проверена.
2) Подмножество субъектов. 20 из 40 доступных субъектов.
3) Неоднозначное свидетельство для MixStyle. Конфирматорный эффект только на UVMD-фронтенде; на Sinc — разведочный.
4) Дескриптивный статус H8. Градиент обученных параметров — наблюдение, а не контролируемый эксперимент.
5) Узкое сравнение SCG-Net. Не сравнивается с другими архитектурами доменной генерализации (DANN, CORAL, DRO).
6) Новизна. Декомпозиция и MixStyle — устоявшиеся методы; наш вклад — их побандовая комбинация для пЭМГ.

VIII. Заключение

Межсубъектная вариабельность пЭМГ имеет выраженную частотную структуру. Глобальные подходы к инвариантности — равномерная нормализация, состязательное разделение контента и стиля — разрушают информацию о жестах и ухудшают качество. Частотно-селективная обработка, где низкочастотные полосы сохраняются, а высокочастотные нормализуются, устойчиво превосходит все проверенные альтернативы.

Конвейер, реализующий эту идею — декомпозиция на четыре поддиапазона + побандовый MixStyle — достигает 37,7% macro-F1 на NinaPro DB2 (20 субъектов, LOSO) по сравнению с опубликованным бейзлайном 33,5%, при этом декомпозиция обеспечивает основной вклад (+3,7 п. п.), а аугментация стилей — дополнительный (+1,1–1,8 п. п.). Три независимых свидетельства — спектральный анализ, обученные параметры адаптивного MixStyle и почти бинарный гейт SCG-Net — согласованно указывают на частотно-зависимую структуру вариабельности.

Результаты получены на одном датасете и требуют валидации на других бенчмарках пЭМГ. В рамках этих ограничений центральный вывод прост: в сигналах пЭМГ субъект-инвариантность следует строить частотно-селективно, а не глобально.

Список литературы

[1] M. Atzori и др., “Deep learning with convolutional neural networks applied to electromyography data: A resource for the classification of movements for prosthetic hands,” Front. Neurorobot., vol. 10, 2016.

[2] M. Atzori и др., “Electromyography data for non-invasive naturally-controlled robotic hand prostheses,” Sci. Data, vol. 1, p. 140053, 2014.

[3] D. Farina и др., “The extraction of neural information from the surface EMG for the control of upper-limb prostheses: emerging avenues and challenges,” IEEE Trans. Neural Syst. Rehabil. Eng., vol. 22, no. 4, pp. 797–809, 2014.

[4] T. S. Saponas и др., “Enabling always-available input with muscle-computer interfaces,” in Proc. UIST, 2009.

[5] E. Campbell и др., “Current trends and confounding factors in myoelectric control: Limb position and contraction intensity,” Sensors, vol. 20, no. 6, 2020.

[6] U. Côté-Allard и др., “Deep learning for electromyographic hand gesture signal classification using transfer learning,” IEEE Trans. Neural Syst. Rehabil. Eng., vol. 27, no. 4, pp. 760–771, 2019.

[7] Y. Du и др., “Surface EMG-based inter-session gesture recognition enhanced by deep domain adaptation,” Sensors, vol. 17, no. 3, 2017.

[8] A. Phinyomark и др., “Feature reduction and selection for EMG signal classification,” Expert Syst. Appl., vol. 39, no. 8, pp. 7420–7431, 2012.

[9] К. Голован, И. Зверева, “Воспроизводимый бенчмарк для межсубъектного распознавания жестов кисти по сигналам пЭМГ,” 2025.

[10] K. Dragomiretskiy, D. Zosso, “Variational mode decomposition,” IEEE Trans. Signal Process., vol. 62, no. 3, pp. 531–544, 2014.

[11] M. Ravanelli, Y. Bengio, “Speaker recognition from raw waveform with SincNet,” in Proc. SLT, 2018.

[12] K. Zhou и др., “Domain generalization with MixStyle,” in Proc. ICLR, 2021.

[13] B. Hudgins, P. Parker, R. N. Scott, “A new strategy for multifunction myoelectric control,” IEEE Trans. Biomed. Eng., vol. 40, no. 1, pp. 82–94, 1993.

[14] K. Englehart, B. Hudgins, “A robust, real-time control scheme for multifunction myoelectric control,” IEEE Trans. Biomed. Eng., vol. 50, no. 7, pp. 848–854, 2003.

[15] E. Scheme, K. Englehart, “Electromyogram pattern recognition for control of powered upper-limb prostheses: State of the art and challenges for clinical use,” J. Rehabil. Res. Dev., vol. 48, no. 6, pp. 643–659, 2011.

[16] S. Pizzolato и др., “Comparison of six electromyography acquisition setups on hand movement classification tasks,” PLoS ONE, vol. 12, no. 10, e0186132, 2017.

[17] X. Zhai и др., “Self-recalibrating surface EMG pattern recognition for neuroprosthesis control based on convolutional neural network,” Front. Neurosci., vol. 11, 379, 2017.

[18] W. Wei и др., “A multi-stream convolutional neural network for sEMG-based gesture recognition in muscle-computer interface,” Pattern Recognit. Lett., vol. 119, pp. 131–138, 2019.

[19] I. Ketykó, F. Kovács, K. Z. Varga, “Domain adaptation for sEMG-based gesture recognition with recurrent neural networks,” in Proc. IJCNN, 2019.

[20] N. E. Huang и др., “The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis,” Proc. R. Soc. Lond. A, vol. 454, pp. 903–995, 1998.

[21] N. Rehman, D. P. Mandic, “Multivariate empirical mode decomposition,” Proc. R. Soc. A, vol. 466, pp. 1291–1302, 2010.

[22] K. Englehart и др., “Classification of the myoelectric signal using time-frequency based representations,” Med. Biol. Eng. Comput., vol. 37, no. 4, pp. 526–532, 1999.

[23] A. Phinyomark, E. Scheme, “EMG pattern recognition in the era of big data and deep learning,” Big Data Cogn. Comput., vol. 2, no. 3, 21, 2018.

[24] D. Borra и др., “Interpretable and lightweight convolutional neural network for EEG decoding: Application to movement execution and imagination,” Neural Netw., vol. 129, pp. 55–74, 2020.

[25] S. Ioffe, C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” in Proc. ICML, 2015.

[26] D. Ulyanov, A. Vedaldi, V. Lempitsky, “Instance normalization: The missing ingredient for fast stylization,” arXiv:1607.08022, 2016.

[27] X. Huang, S. Belongie, “Arbitrary style transfer in real-time with adaptive instance normalization,” in Proc. ICCV, 2017.

[28] S. Sagawa и др., “Distributionally robust neural networks for group shifts: On the importance of regularization for worst-case generalization,” in Proc. ICLR, 2020.

[29] M. Arjovsky и др., “Invariant risk minimization,” arXiv:1907.02893, 2019.

[30] Y. Ganin и др., “Domain-adversarial training of neural networks,” J. Mach. Learn. Res., vol. 17, no. 59, pp. 1–35, 2016.

[31] J. Wang и др., “Generalizing to unseen domains: A survey on domain generalization,” IEEE Trans. Knowl. Data Eng., vol. 35, no. 8, pp. 8052–8072, 2023.

[32] S. Holm, “A simple sequentially rejective multiple test procedure,” Scandinavian J. Statistics, vol. 6, no. 2, pp. 65–70, 1979.